

SUBARU打ち合わせ資料(プレス関連)
Oct. 14th, 2021

令和3年10月研究打ち合わせ

群馬大学 大学院 理工学府
橋本 誠司

研究目的と内容

■研究題目：

- プレス生産設備の故障予知

■研究目的及び内容

- プレス機から得られる情報(熱, 振動, 音)を元に故障の兆候を掴み, 設備故障による停止を回避する技術を確立
- 本工場Lライン(サーボプレス)をモデルラインとして予防保全 → 予知保全の技術を確立

研究内容

■ 予知・予防保全までの流れ

1. データ解析(正常・異常の分類)
2. 故障の兆候(原因)の把握
3. 予知・予防保全

1. データ解析(正常・異常の分類)

Step 1: アウトライア(異常値)の除去 ⇒ 信号処理

Step 2: 4軸分類 ⇒ 信号処理

Step 3: 各軸(あるいは全軸)での正常／異常の分類 ⇒ NN

- 診断の可視化(エッジ, 振幅, 振動など) ⇒ Grad-CAM
- 軸間の干渉, 多軸での診断 ⇒ 信号処理, NN
- 経年劣化, 製品差 ⇒ 教師なし学習

研究内容

■ データ収集

- プレス機から得られる情報(熱, 振動, 音)の収集
⇒ 故障時のデータはあるか, 故障の種類はわかるか etc.
- (先行して)シミュレーション, HILS等によるセンサ情報の取得は可能か？



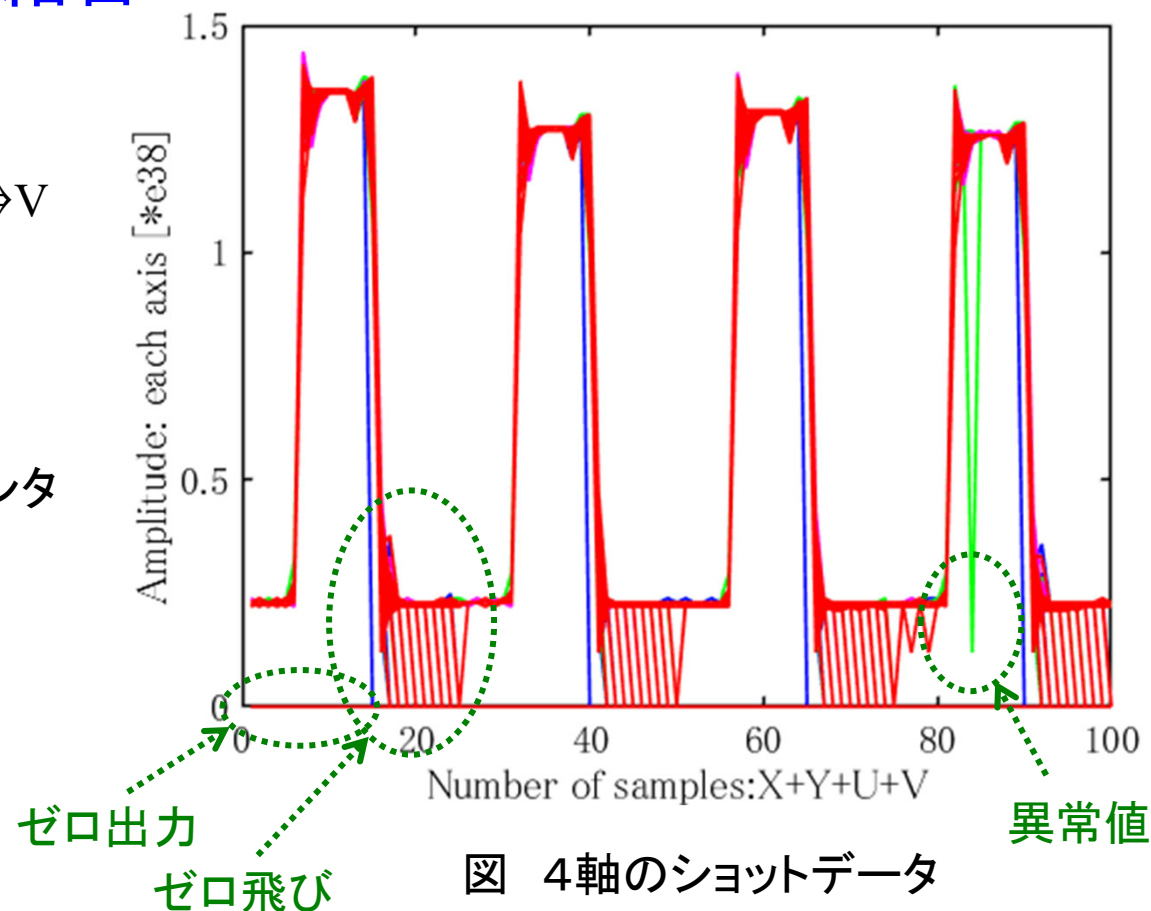
ニューラルネットワークによる 分類・診断法

～ ゼロ飛びデータの分類 ～

■ 圧力データ: 4軸結合

プロット条件

- 4軸のデータをX⇒Y⇒U⇒Vの順に接続
- プロットの線色;
 - 1~500ショット⇒青
 - 501~1000ショット⇒緑
 - 1001~1500ショット⇒マゼンタ
 - 1501ショット以降⇒赤
- データへの前処理:
[数値] × 1e38




- 異常値(ゼロ出力, ゼロ飛び, 異常値)の混入が確認できる
- 4軸で振幅の差が(目視でも)確認できる



■現状の課題

- サンプルング時間が不十分(時間分解能が低い)
- 振幅の分解能が低い(量子化分解能が低い)

振動波形の解析, 時間分解能が低い場合
にも有効な手法



畳み込みニューラルネットワーク(CNN)
に基づく画像診断法

異常値のCNN分類

(R3.3.26報告内容) No. 8



Gunma University, JAPAN


■ 診断画像

条件


- 軸: 4軸
- 転移学習
(DenseNet201)
- 学習率可変
- 画像拡張有
- データ数: 各400枚
(飛無319, 飛有81)
(学習: 検証
=70%:30%)



ゼロ飛びをCNN
で正しく分類で
きるか検証



(a) ゼロ飛びなし(正常)



(b) ゼロ飛びあり(異常)

図 診断画像例

異常値のCNN分類

(R3.3.26報告内容) No. 9



■ 転移学習

【学習】

第1世代

→ 精度31.3 %

第7世代以降

→ 精度100 %

【検証】

→ 精度99.2 %

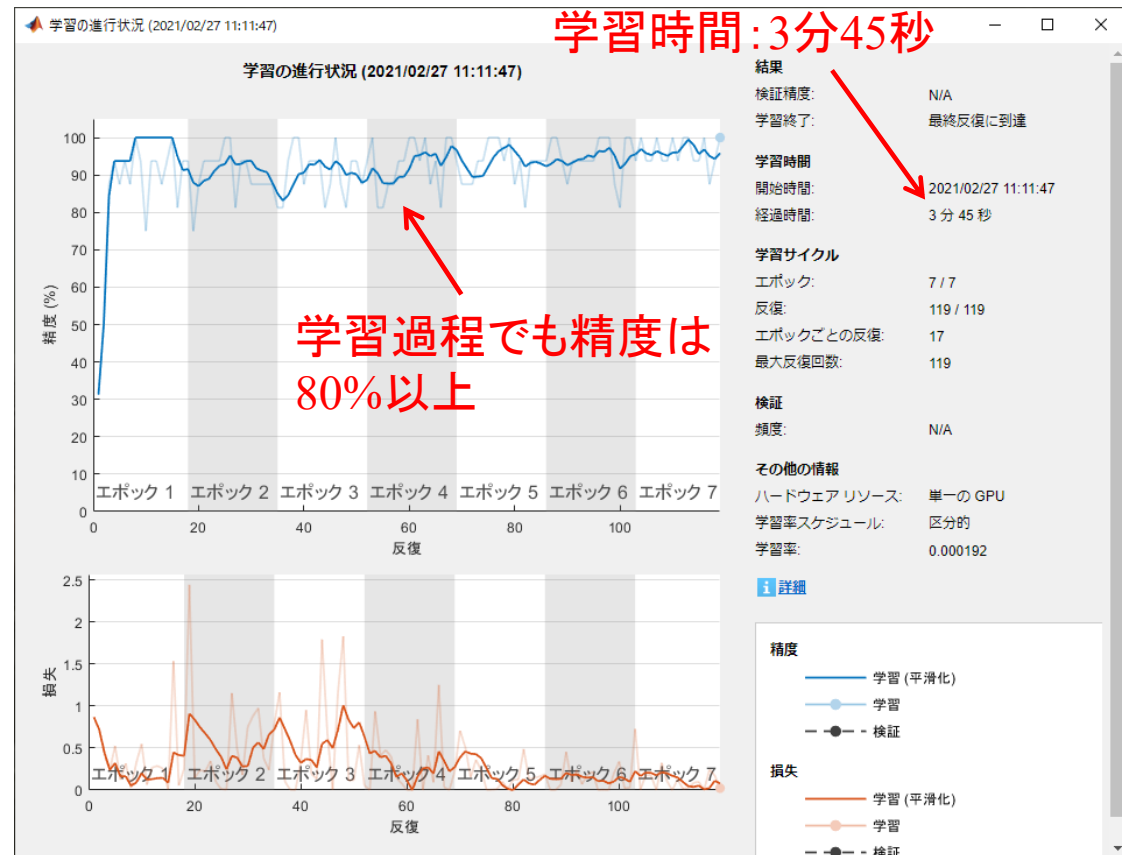


図 学習および検証結果例

検証データ: 正常96, 異常24
→ 120画像中1枚が誤判定

⇒ ゼロ飛びの分類は可能！




■ Grad-CAMによる判定理由の解析


画像のどこに着目して学習しているか確認

正分類


Predicted: OK (99.9958%)



Predicted: NG (100%)



Predicted: NG (100%)



誤分類

Predicted: NG (97.4656%)




図 Grad-CAMによる解析結果(正解)

図 Grad-CAMによる解析結果(不正解)

- ゼロ近傍に正しく着目して判断している
- 誤判定画像: ゼロ飛びなしのデータにも, きわめてゼロに近いデータがある(ゼロ飛びとみなしてよいのでは!?)

ニューラルネットワークによる 分類・診断法 ～ 教師なし学習 ～

学習: 4軸の正常データのみ

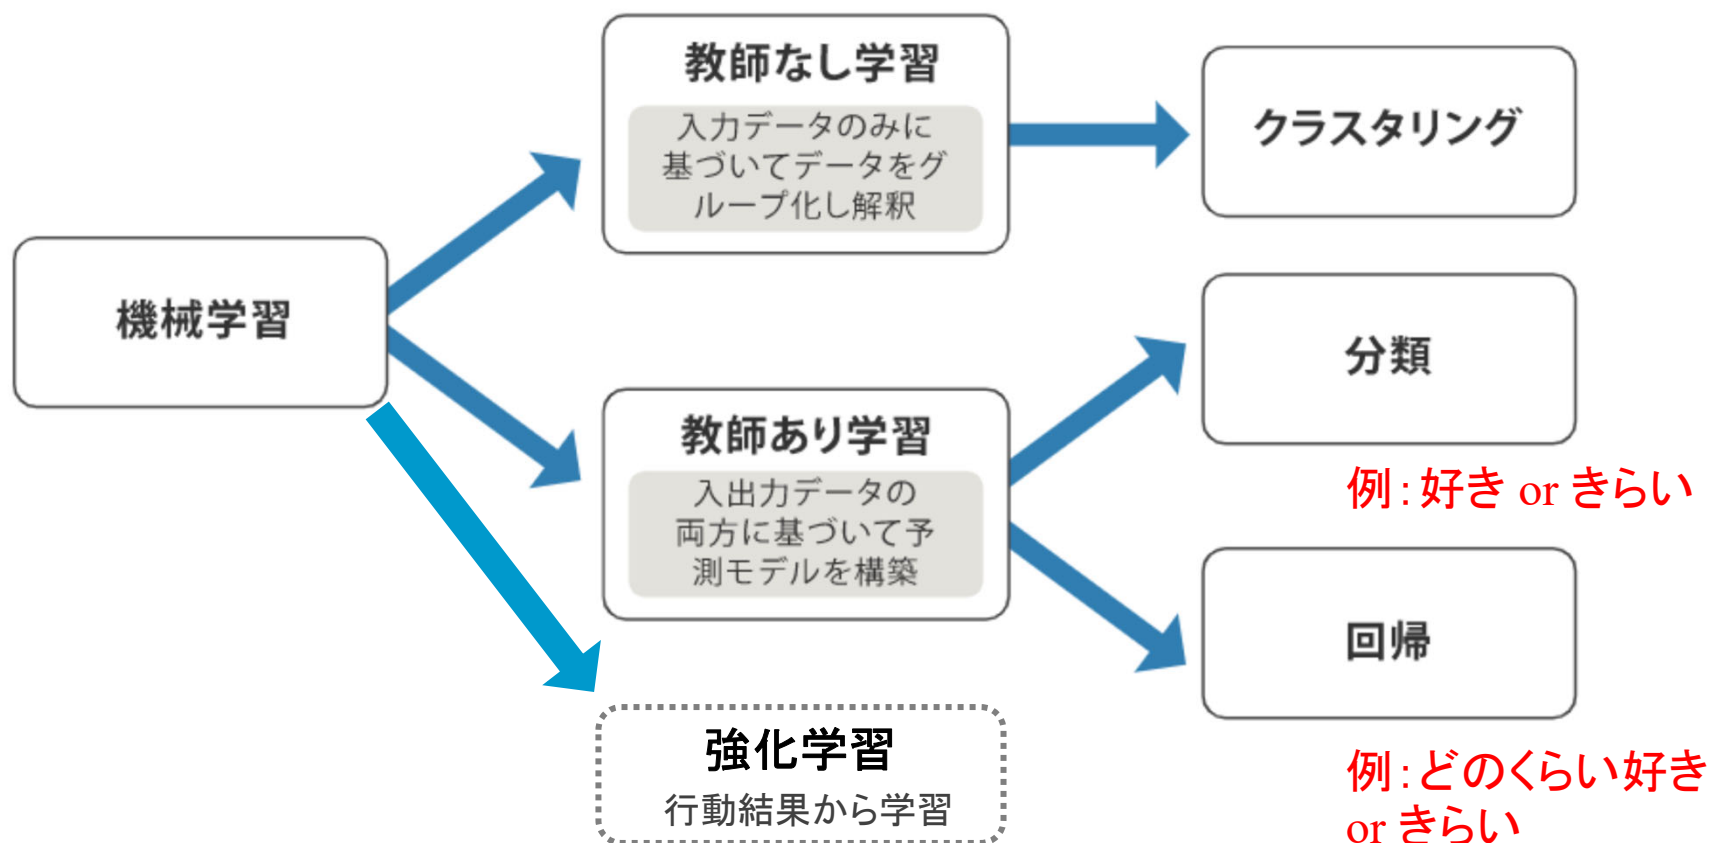
⇒ 検証: 4軸のゼロ飛びを正常データからの距離で
判断可能か検証

距離計算のための変数

⇒ 1ショットの時系列データ(100点)

教師なし学習の導入

■機械学習の分類



出典 <https://jp.mathworks.com/discovery/machine-learning.html>

教師なし学習の導入

■教師なし学習

- 学習データに正解を与えない状態で学習させる手法
- 正常からのどの程度逸脱しているか数値化し判断
- 異常検知などで学習データが少ない場合に有効
- 教師なし学習法: クラスタリング, 主成分分析, アソシエーション分析, GANなど

■クラスタリング



- データ間の類似度にもとづいて, データをグループ分けする手法

教師なし学習の導入



■ クラスターリングの分類

- 階層クラスターリング ⇒ 似ている組み合わせからまとめていく手法で、結果を樹形図で見ることができる
- 非階層クラスターリング ⇒ グループの数を決める必要がある代わりに、データ量が多い場合も対応可能

階層クラスターリング



非階層クラスターリング



分類について

■ クラスター分類のポイント

参照

https://www.albert2005.co.jp/knowledge/data_mining/cluster/cluster_summary

1. グループ分けの対象

サンプルを分類するのか, 変数を分類するのか

⇒ 目的が決まれば自動的に決まる

2. 分類(種類, 生成)の形式

階層的方法か非階層的方法か

⇒ ビッグデータではほぼ非階層的方法

3. クラスターの合併方法(クラスター間の距離の測定方法)

ウォード法、群平均法、最短距離法、最長距離法・・・

⇒ 非階層的方法では選択の必要は無い

4. 分類に用いる対象間の距離(類似度)

ユークリッド距離, マハラノビス距離, チェビシェフ距離 ...

⇒ 最も大きな問題

分類で利用する距離について




Gunma University, JAPAN

■ ユークリッド距離

- 2点間の直線距離

(例) 2変量: $d_E^2 = X^2 + Y^2$
(X, Y :正規化値)



■ マハラノビス距離

- 多変量(多次元)空間における距離尺度のひとつ
- 変量間の相関を考慮した距離

(例) 2変数: (r :相関係数)

$$d_M^2 = \frac{1}{2} \begin{bmatrix} X & Y \end{bmatrix} \begin{bmatrix} 1 & r \\ r & 1 \end{bmatrix}^{-1} \begin{bmatrix} X \\ Y \end{bmatrix}$$

相関係数行列の逆行列(\Rightarrow 変量分のサイズ)

注) データ数が変量数以下の場合は逆行列計算不可




図 多変量への各種距離
(原点間距離=1)

分類で利用する距離について



Gunma University, JAPAN

マンハッタン距離

- 座標間距離の和
- 碁盤の目の経路でえられる距離
- 2進数データ(0 or 1)の分類に有効

(例) 2変量: $d_M = |X| + |Y|$

(X, Y :正規化値)

座標(1,1) $\Rightarrow d_E=1.4, d_M=2$

チェビシェフ距離

- 座標間距離の最大値
- ノイズのあるデータに有効

(例) 2変量: $d_C = \max(|X|, |Y|)$

座標(1,0.1) $\Rightarrow d_E=1.005, d_C=1$





図 多変量への各種距離
(原点間距離=1)

分類で利用する距離について

■ マハラノビスの距離の例





図 等マハラノビス距離線(相関係数 $r=0.8$)



相関係数 r とマハラノビス距離


【A君とB君の数学&物理の点数の集団(原点:クラス平均)からの距離】

- ユークリッド距離では等しい
- マハラノビス距離では3倍離れている
- 相関のある集団への類似度: 相関方向⇒近, 無相関⇒遠

■ 診断データ

条件

- 軸: 4軸 (100点/shot/4 axes)
- 教師なし学習
 - 4軸1ショット分の時系列データの距離差
 - 距離算出: **ユークリッド距離, マハラノビスの距離(MTS表示)**
- データ数: 2,144枚 (正常1701, 異常443)
 - 学習: 4軸の異常値無し画像 (1,600枚)
 - 検証: 4軸の異常値無し画像 (101枚: 学習とは別データ), 異常 (443枚)




ゼロ飛びの有無を距離差で判別可能か検証

異常値の教師なし学習による分類 ～ 時系列データ処理 ～

No. 20




■ 診断データ




飛無: 1,600ショットの時系列データ

学習用データ(正常のみ)



飛無: 101ショット



飛有: 443ショット

検証用データ(正常 & 異常)



■ 検証データに対する距離




図 ユークリッドの距離




図 マハラノビス距離(MTS)

- 時系列信号で距離差を算出
- 距離差(最大値比率): ユークリッド $\Rightarrow +1.63\%$ (9.48%: 上の3つ除)
マハラノビス $\Rightarrow +0.34\%$ (42%: 上の3つ除)

※ マイナス値は重なり

マハラノビス距離の拡大図

■ 検証データに対する距離

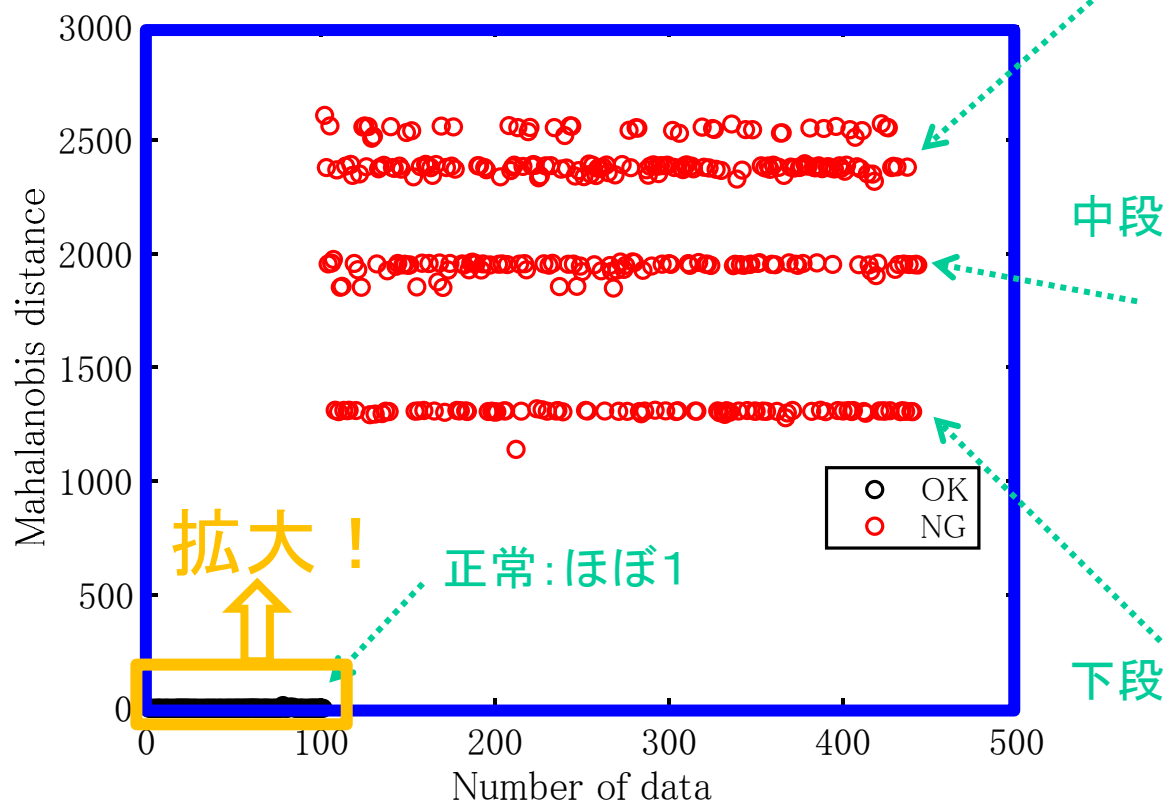



図 マハラノビス距離(拡大図)

- 異常データの差は階段的
⇒ 3つの特徴的な飛び(幅)がある!?



マハラノビス距離の拡大図2

■ 検証データに対する距離





図 マハラノビス距離(拡大図)

- 正常データ中でも、わずかな異常値を検出可能そう!?


ギヤ破損時のAEデータのプロット ～ サンプルデータ ～

【データの計測条件】

- プレス機のギヤ破損時のAEセンサ出力(一部)
- 出力値(Binary signal :13bit)
 - ⇒ 電圧値への変換式 = $x_{bin} \times 5 \text{ [V]} / 2^{13}$
- サンプリング時間: 0.1ms(データ数10,000)

AE技術について

- **Acoustic Emission(AE)**とは？
 - 材料変形, き裂, 摩耗 ⇒ 弾性エネルギー ⇒ 弾性波(高周波信号: 数k~数MHz)として放出
- **AEセンサ** ⇒ 弾性波を検出するセンサ
- AE技術の**用途**は？
 - 材料のクラックの発生, 進行を非破壊で把握
 - 超音波センサ, X線検査と並び広く利用



「アコースティックエミッション計測の基礎」,
精密工学会誌, Vol.78, No.10, pp856-861, 2012

AE技術について

• AE技術の特徴は？

- 変形, き裂, 摩耗の1次的現象である弾性波を捉えられる。他の多くのセンサ(振動, 温度等)は, 2次的現象がほとんど
- 取り付けが容易(方向性もなく, 波の伝搬範囲ならよい)
- ノイズの影響を受けやすい

■ AE

➡ き裂、摩耗などの 1 次的現象 そのものを計測

■ 電流



■ 温度



■ 振動



■ 歪




■ 加速度

} 2 次的現象 を計測早期に状態変化を
捉えられるのが魅力<https://www.inrevium.com/pickup/aesensor/>

AE技術について

- **AE技術の対象設備は？**

- 多軸ロボット(減速機), プレス機(ベアリング, パンチ刃), 溶接機(状態変化), NC機(チッピング), 射出成形機(ベアリング)




プレス機へのAE技術応用

<https://www.inrevium.com/pickup/aesensor/>

AE技術について

• AE技術の異常検知・診断システムは？

- データ収集・可視化・変化監視・通知のシステム化が必要
- 変化の監視では、最適な閾値で監視し可視化する仕組みが重要 ⇒ AI応用！




<https://www.inrevium.com/pickup/aesensor/>

AE技術について

• AE評価パラメータは？

- AE時間信号波形(最大振幅, 立ち上がり時間, 持続時間)
- AE周波数(時間周波数解析)
- AE平均値, AE実効値,
- AE計数率(単位時間あたりのAE発生率)など



「アコースティックエミッション計測の基礎」,
精密工学会誌, Vol.78, No.10, pp856-861, 2012

サンプルデータのプロット

■ ギヤ破損時のAEデータのパワースペクトラム

- 分解能: 0.61mV ($=5V/2^{13}$)
- サンプルング時間: 0.1ms





図 AEデータ(電圧出力)



周波数解析データ

サンプルデータのプロット

■ ギヤ破損時のAEデータのスペクトログラム

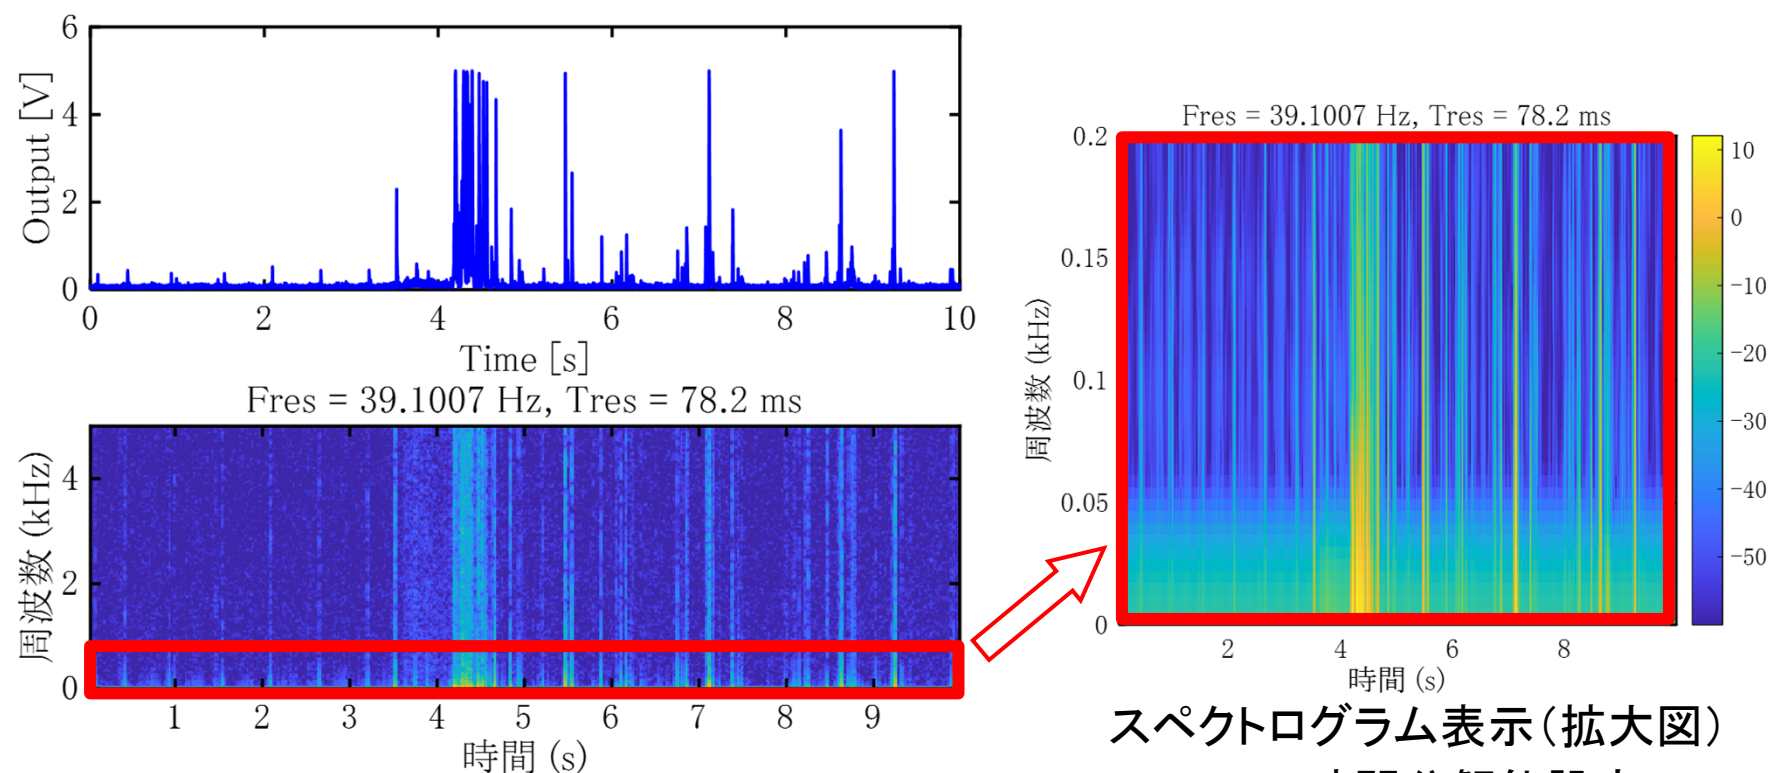


図 原信号とスペクトログラム表示

付 録

■MTS法を用いた推定法

1. 新品のデータ ⇒ 単位空間(マハラノビス空間)を決定
2. 経年劣化品のデータ ⇒ 劣化と高い相関があると予想した評価項目群のマハラノビス距離を測定
3. データ劣化に対する感度(SN比で表現)が高い評価項目を抽出
4. 抽出した評価項目に対するマハラノビス距離と、閾値により劣化診断
5. (加えて)マハラノビス距離と寿命の相関を示す物理量などにより余寿命を推定

■MTS法(ホテリング理論)の課題

1. 異常度が、単一の正規分布に従うと仮定 \Rightarrow いくつかの動作モードがある場合(機械系など), 誤報が頻発する可能性
2. 多変数系の異常度を単一指標で表すため, 変数が多くなるにつれ, 少数の変数のみに生じる異常がかき消される
3. 異常度の定義が平均値からのずれ \Rightarrow 値が動的に変化する系では適用が困難


研究内容

■ 参考資料

～発生防止の取組み～

成形シミュレーションにより不具合を事前に把握し、デジタル上で対策を実施

“われ”解析



“線ずれ”解析

